Язык C

Этапы развития языка

- Разработка – 1970е
- 1978 – Kernighan, Ritche. The C Programming Language
- 1989 – ANSI C
- 1999 – стандарт ISO C99
- 2011 – стандарт ISO C11
- C и C++ развиваются параллельно и согласованно (например, memory model)

Ядро ОС и C++

- В основном, ядра операционных систем написаны на Си
- Symbian — практически полностью C++
- Windows, MacOS — драйвера можно разрабатывать на подмножестве C++

- Причины: 1) исторические — разработка началась в то время, когда C++ не было
- Объем кода — десятки млн. строк кода — затраты на перенос на C++

Ядро ОС и C++

- Технические причины: «Узкие места» C++
  - Исключения:
    - Либо накладные расходы на таблицы обработки исключений (раздувание кода)
    - Либо накладные расходы на поддержку стековых фреймов при работе (замедление работы)
    - «непрозрачные» передачи управления при работе
  - Динамическая память (STL):
    - Страницы памяти, занятые ядром, никогда не смогут использоваться в приложениях — требуется контроль за использованием памяти
  - «Непрозрачная» генерация кода

Реализации Си

- Freestanding реализация – поддерживается ограниченный набор заголовочных файлов и стандартных функций (например, memcpy)
  - Для ядер операционных систем
  - Для встроенных систем (embedded) без управления ОС
- Hosted реализация – полный набор (возможно, кроме опциональных) заголовочных файлов и библиотечных функций
  - Программирование на уровне пользовательских программ ОС

Стандартная библиотека Си (hosted в Linux)

- В Unix системах традиционно называется libc, является частью ОС
- Заголовочные файлы размещаются в /usr/include
- Бинарный динамически загружаемый файл: /lib/libc.so.6 (Linux)
- Помимо функций библиотеки Си содержит и функции POSIX и расширения
- Библиотека математических функций отдельно – libm – требуется опция -lm при компиляции

Взаимодействие программы на Си с окружением

- Стандартные потоки ввода и вывода stdin, stdout, stderr
- Аргументы командной строки
- Переменные окружения
- Код завершения программы

Обработка ошибок

- Библиотечные функции и системные вызовы в случае ошибки возвращают специальное значение (например, fopen возвращает NULL, часто возвращается -1)
- В этом случае переменная errno содержит код ошибки, например, EPERM, EAGAIN
- Переменная errno и коды ошибок определены в <errno.h>
- strerror из <string.h> возвращает строку, соответствующую ошибке
- Сообщения об ошибках должны выводиться на stderr

Взаимодействие со средой

- Процесс завершается системным вызовом _exit(exitcode)
- Или возвращаемое значение return из main
- Значение в диапазоне [0;127] — код завершения процесса, он доступен процессу-родителю
- Код 0 — успешное завершение (/bin/true)
- Ненулевой код — ошибка (/bin/false)

Аргументы командной строки

- Функция main получает аргументы командной строки:

  int main(int argc, char *argv[])

- argv — массив указателей на строки Си

  ./prog foo 1 bar

  argv[0] →"./prog"; путь к программе
  argv[1] →"foo";
  argv[2] →"1";
  argv[3] →"bar";
  argv[4] →NULL;

- Передаются на стеке процесса

argv[0]

- Обычно argv[0] – путь, использованный для запуска программы
- Некоторые программы анализируют argv[0] и модицифируют свое поведение (например, busybox)

Переменные окружения

- Именованные значения доступные процессу
- По умолчанию передаются неизменными порождаемым процессам

  char *getenv(const char *name);
- В процесс передаются на стеке
- Глобальная переменная environ содержит указатель на массив переменных

Представление целых чисел

Биты

- Двоичная система счисления – натуральна для элементной базы (манипулирование напряжением для передачи сигнала, транзисторные ключи и т. д.)
- Попытки использовать симметричную троичную систему { -1, 0, 1 } - ЭВМ “Сетунь”
- Некоторые теоретические преимущества не оправдываются усложнением схемотехники

Byte vs Octet

- Почти всегда говоря “байт” мы подразумеваем “8 бит” - строго говоря, это не так
- С точки зрения стандартов C/C++ byte == char – минимальная адресуемая единица памяти
- sizeof(char)== 1
- Количество бит в char определяется константой CHAR_BIT
- Стандарт требует CHAR_BIT >= 8
- Если память можно адресовать только по 16-битным словам, то CHAR_BIT == 16
- Октет – всегда 8 бит

Byte (unsigned char)

- Далее будем предполагать что CHAR_BIT==8
- Беззнаковые целые числа представляют значения [0;2^N-1], N – число бит
- Unsigned char позволяет представлять значения [0; 255]

Нумерация битов

- Индивидуальные биты в байте не адресуются, но для удобства мы их нумеруем
- 0 – младший (самый правый в двочной записи) бит
- 7 – старший (самый левый в двоичной записи) бит

Нумерация битов

-

Байт (8 бит)

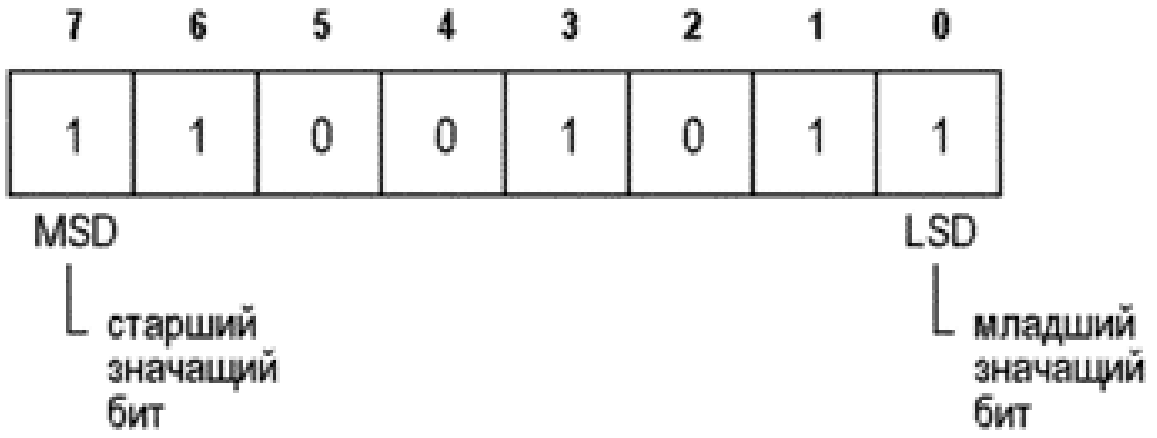

Слово (16 бит)

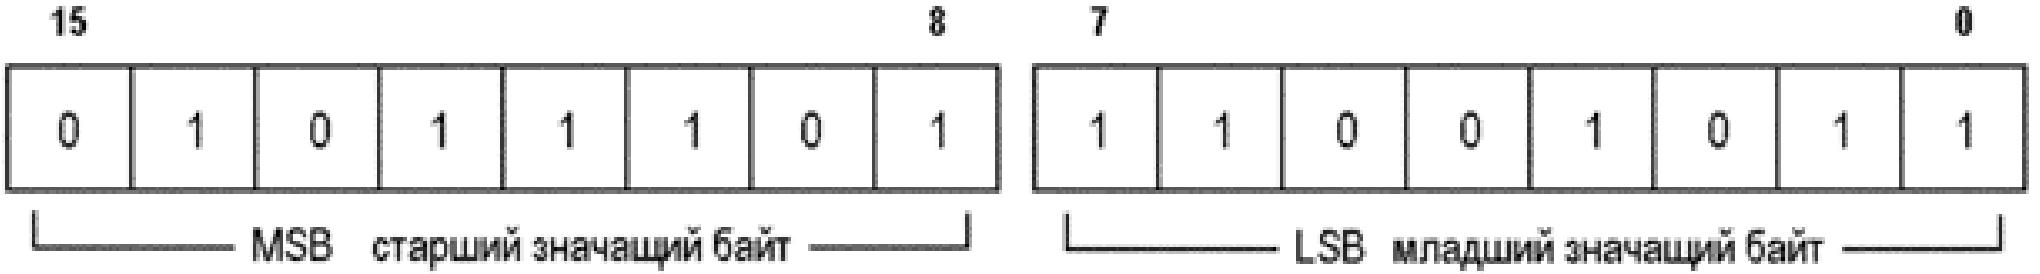

Битовые операции

- ~, &, |, ^ - применимы к целым числам
- Каждый бит операндов рассматривается независимо

And

- A&B = 1 when both A=1 and B=1

&	0	1
0	0	0
1	0	1

Or

- A|B = 1 when either A=1 or B=1

|	0	1
0	0	1
1	1	1

Not

- ~A = 1 when A=0

~	
0	1
1	0

Exclusive-Or (Xor)

- A^B = 1 when either A=1 or B=1, but not both

^	0	1
0	0	1
1	1	0

Битовые вектора для множеств

- В 8-битном числе храним множество не более чем из 8 эл-тов {0,1,2,3,4,5,6,7}
  - 01101001 { 0, 3, 5, 6 }
  - 76543210
  - 01010101 { 0, 2, 4, 6 }
  - 76543210
- Операции
  - & - Пересечение – 01000001 - { 0, 6 }
  - | - Объединение – 01111101 - { 0, 2, 3, 4, 5, 6 }
  - ^ - Симметрическая разность – 00111100 - { 2, 3, 4, 5 }
  - ~ - Дополнение (ко второму множеству) – 10101010 - { 1, 3, 5, 7 }

Сдвиги (беззнаковые)

- Сдвиг влево: x << n
  - Пример (для 8 битных беззнаковых чисел)
  - 01101100 << 3 == ~~(011)~~01100*000*
  - Эквивалентно умножению на 2^n
- Сдвиг вправо: x >> n
  - 01101100 >> 4 == *0000*0110~~(1100)~~
  - Эквивалентно целой части от деления на 2^n

Знаковые числа

- Необходимо кодировать знак числа в N бит представления числа
- Стандарты Си/Си++ допускают три типа представления знаковых чисел
  - Прямой код (sign-magnitude)
  - Обратный код (one's complement)
  - Дополнительный код (two's complement)

Прямой код

Положительное	Двоичное	Прямой код
0	0000	0
1	0001	1
2	0010	2
3	0011	3
4	0100	4
5	0101	5
6	0110	6
7	0111	7
8	1000	-0
9	1001	-1
10	1010	-2
11	1011	-3
12	1100	-4
13	1101	-5
14	1110	-6
15	1111	-7

Обратный код

Положительное	Двоичное	Прямой код
0	0000	0
1	0001	1
2	0010	2
3	0011	3
4	0100	4
5	0101	5
6	0110	6
7	0111	7
8	1000	-7
9	1001	-6
10	1010	-5
11	1011	-4
12	1100	-3
13	1101	-2
14	1110	-1
15	1111	-0

Дополнительный код

Положительное	Двоичное	Прямой код
0	0000	0
1	0001	1
2	0010	2
3	0011	3
4	0100	4
5	0101	5
6	0110	6
7	0111	7
8	1000	-8
9	1001	-7
10	1010	-6
11	1011	-5
12	1100	-4
13	1101	-3
14	1110	-2
15	1111	-1

Знаковые числа

- Старший разряд – знаковый
  - 0 – положительные числа
  - 1 – отрицательные числа
- Практически универсально используется дополнительный код
- UNISYS 2200 – обратный код
- Прямой код – мантисса представления IEEE-754 вещественных чисел

Дополнительный код

- -x = ~x + 1
- Несимметричный диапазон, например, для signed char - [-128; 127]
- Рассмотрим далее 4-битные числа: [-8; 7]
- Ограниченная разрядность – сохраняются только младшие биты результата соотв. разрядности (например, 4), старшие биты – теряются
- Примеры в двоичной системе:
  - -0000 = ~0000 + 1 = 1111 + 1 = ~~1~~0000 → 0
  - -1000=~1000+1=0111+1=1000
  - 0110+(-0110)=0110+ (~0110+1)=0110+(1001+1)=(0110+1001+1)=1111+1 =~~1~~0000 → 0

Удобство дополнительного кода

- Операции сложения и вычитания n-битных беззнаковых чисел дают правильный результат для знаковых чисел
- В процессоре не нужно различать знаковые и беззнаковые числа при сложении и вычитании – меньше инструкций, проще аппаратура
- Для 4-битных чисел (0b – запись двоичного числа в Си):
  - 5 + 9 = 0b0101 + 0b1001 = 0b1110 = 14
  - 5 + (-7) = 0b0101 + 0b1001 = 0b1110 = -2
  - 12+13 = 0b1100 + 0b1101 = 0b1̶1001 = 9 – беззнаковое переполнение
  - -4+(-3) = 0b1100 + 0b1101 = 0b1̶1001 = -7 – со знаковыми ОК

Типы char в Си/Си++

- sizeof(char) == sizeof(signed char) == sizeof(unsigned char) == 1
- Char может быть либо знаковым, либо беззнаковым (implementation defined behavior)
- На x86/x64 char – знаковый, на ARM char – беззнаковый
- Но формально char и signed char (или char и unsigned char) – разные типы
- GCC позволяет переключаться между режимами: -fsigned-char -funsigned-char
- Программа должна быть корректной в любом случае

Byte order

- Память адресуется побайтно
- Целые числа большей длины могут размещаться в памяти по-разному
- Преобразование прозначно для программиста
- Little-endian: x86
- Big-endian: SPARC
- Переключаемые: ARM, PPC (Android — LE, iOS – LE)
- Подавляющее большинство компьютерных систем в настоящее время работает в режиме LE

Byte order

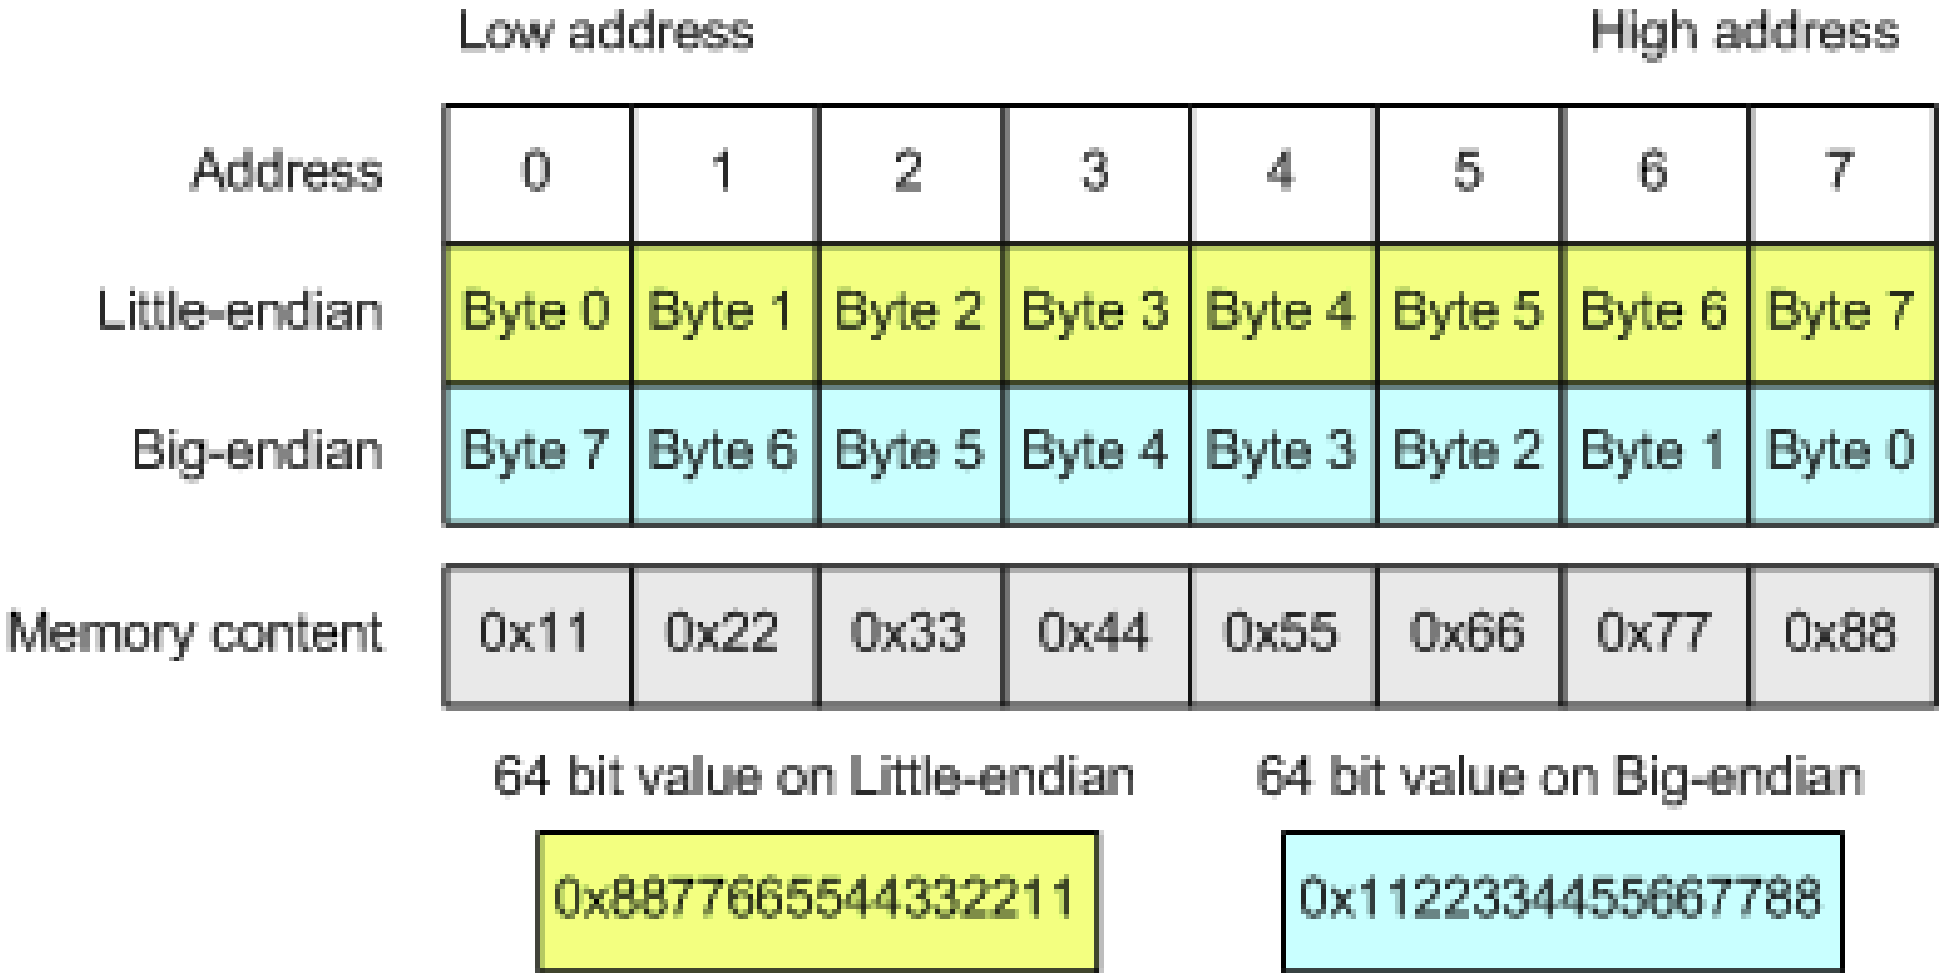
Low address
High address
Address
0
1
2
3
4
5
6
7
Little-endian
Byte 0
Byte 1
Byte 2
Byte 3
Byte 4
Byte 5
Byte 6
Byte 7
Big-endian
Byte 7
Byte 6
Byte 5
Byte 4
Byte 3
Byte 2
Byte 1
Byte 0
Memory content
0x11
0x22
0x33
0x44
0x55
0x66
0x77
0x88
64 bit value on Little-endian
0x8877665544332211
64 bit value on Big-endian
0x1122334455667788

Типы данных в Си/Си++

- sizeof(char) <= sizeof(short) <= sizeof(int) <= sizeof(long) <= sizeof(long long)
- sizeof(float) <= sizeof(double) <= sizeof(long double)
- sizeof(signed T) == sizeof(unsigned T)
- Преобразование знаковое ↔ беззнаковое сохраняет битовое представление
- Преобразование более “широкого” значения в более “узкое” отсекает старшие биты

Расширение типа

- Беззнаковое расширение: unsigned char → unsigned short – дополнение нулями
  - 0b11100011 → 0b00000000 11100011
- Знаковое расширение: signed char → signed short
  - 0b01110011 → 0b00000000 01110011
  - 0b11100011 → 0b11111111 11100011

Sizeof для типов

Тип	Atmel AVR	32-bit	Win64	64-bit
`char`	1	1	1	1
`short`	2	2	2	2
`int`	2	4	4	4
`long`	4	4	4	8
`long long`	-	8	8	8
`__int128 !`	-	-	-	16
`float`	4	4	4	4
`double`	4	8	8	8
`long double`	4	8 или 12	8	16
`void *`	2	4	8	8

Максимальные/минимальные значения типов

- C++
  - #include <limits>
  - std::numeric_limits<T>::max()
  - std::numeric_limits<T>::min()
- C
  - #include <limits.h>
  - CHAR_MIN, CHAR_MAX, SCHAR_MIN, SCHAR_MAX, UCHAR_MIN, …, INT_MIN, INT_MAX, UINT_MAX, LONG_MIN, LONG_MAX, ULONG_MAX, LLONG_MIN, LLONG_MAX, ULLONG_MAX

Типы фиксированной битности

- Заголовочный файл <stdint.h>
  - Знаковые типы: int8_t, int16_t, int32_t, int64_t
  - Беззнаковые типы: uint8_t, uint16_t, uint32_t, uint64_t
  - Типы размера, достаточного для хранения указателя: intptr_t, uintptr_t
- Дополнительно в <inttypes.h>:
  - Макросы для printf и scanf для использования этих типов: PRId32, …
  - printf("%" PRId64 "\n", t);

Переполнение беззнаковых чисел

- Все операции над беззнаковыми числами выполняются по модулю 2^N (N – битность)
- Поведение строго определено стандартом
- UINT_MAX + 1 == 0
- 0 - 1U == UINT_MAX

Implementation-defined behavior

- Каждая реализация компилятора Си/Си++ должна реализовывать implementation-defined behavior разумным образом (одним из нескольких предопределенных вариантов) и документировать это поведение
- Пример: представление отрицательных чисел

Unspecified behavior

- Каждая реализация компилятора Си/Си++ может реализовывать unspecified behavior по-разному, даже в пределах одной программы, не обязана документировать. Unspecified behavior – это корректное (но недетерминированное) поведение корректной программы
- Пример: порядок вычисления аргументов при вызове функции

Undefined behavior

- Если программа выполнила операцию, описанную как undefined behavior, дальнейшее поведение программы **не определено** – это ошибочная программа
- Варианты поведения: ignore, crash, burn computer
- Примеры: разыменование нулевого указателя, выход за пределы массива

Undefined behavior

- Компилятор Си/Си++ вправе предполагать, что при выполнении программы **никогда не произойдет** undefined behavior и использовать это при оптимизации

```
*p = 'a';
if (!p) {
  fprintf(stderr, “NULL pointer\n”); return;
}
```

- if можно удалить, исходя из предположения выше

Операции со знаковыми значениями

- Преобразование широкого типа к знаковому узкому, при условии, что значение непредставимо узким знаковым типом – implementation defined (обычно truncation)
  - Пример: (char) 384 == -128
- Сдвиг отрицательного числа вправо – implementation defined (обычно знаковый бит остается на месте – арифметический сдвиг)

Операции со знаковыми значениями

- Переполнение при выполнении знаковых операций +, -, *, /, % - undefined behavior
  - Для компилятора N < N + 1 выполняется всегда!
- Сдвиг на число бит, большее размера типа – undefined behavior
- Сдвиг отрицательного числа влево – undefined behavior
- Сдвиг на отрицательную величину – undefined behavior

Опции gcc

- -ftrapv – abort() при знаковом целочисленном переполнении
- -fwrapv – выполнять знаковые операции по модулю 2^N, но компилятор не делает никаких оптимизационных предположений
- -fsanitize=undefined – проверка на undefined behavior при работе программы

Gcc intrinsics

- GCC поддерживает “встроенные функции” для выполнения операций с контролем переполнения
- В программе на Си они выглядят как вызовы функций __builtin_*
- Транслируются в машинные инструкции, эффективно проверяющие переполнение

__builtin_add_overflow

- Сложение с контролем переполнения

```
int v1 = …, v2 = …;
int res;
if (__builtin_add_overflow(v1, v2, &res)) {
  // обработка случая переполнения
}
```

- При использовании intrinsics никакого UB!